

DSL 베이지안 통계 <기초반>



# Monte Carlo Estimation & Markov Chains

발표자 : 5기 박채은

## 몬테카를로 추정

몬테카를로 방법을 이용하여 알고 싶은 값을 **추정**하는 것

- 몬테카를로 방법

무작위 추출된 난수(random number)를 이용하여 함수의 값을 계산하는 통계학적 방법

```
theta = rgamma(n=m, shape=a, rate=b)
```

```
mean(theta) # sample mean
```

- R을 이용한다면?

1. rgamma, rbeta 등을 이용하여 **random하게 sample**을 뽑는다.
2. 뽑힌 sample을 사용해서 연산을 하여 **구하고자 하는 값을 추정**한다.

- Important quantities 예시)

평균, 분산, 어떤 사건의 확률, 백분위수(quantiles)

## 몬테카를로 추정이 필요한 이유는?

Integration을 이용한 계산이 힘들어서

예시)  $\theta \sim \text{Gamma}(a, b)$

평균: 
$$E(\theta) = \int_0^{\infty} \theta f(\theta) d\theta = \int_0^{\infty} \theta \frac{b^a}{\Gamma(a)} \theta^{a-1} e^{-b\theta} d\theta.$$

분산: 
$$\text{Var}(\theta) = \int_0^{\infty} (\theta - E(\theta))^2 f(\theta) d\theta.$$

계산 복잡!

=> 이렇게 하지 말고 분포에서 sample을 뽑아서 원하는 값을 추정하자

=> 분포에서 sample m개를 뽑아서 표본 평균과 표본 분산을 계산 가능 -> 추정

$$\theta \sim \text{Gamma}(a, b)$$

$$\theta_i^* \quad i = 1, 2, \dots, m$$

표본 평균:  $\bar{\theta}^* = \frac{1}{m} \sum_{i=1}^m \theta_i^*$   $\longrightarrow$

표본 분산:  $\frac{1}{m} \sum_{i=1}^m (\theta_i^* - \bar{\theta}^*)^2$

CLT

$$\bar{X} \sim N\left(E(X), \frac{\text{Var}(X)}{m}\right)$$

## 몬테카를로 추정을 통해 다양한 integrals 계산 가능

예) 어떤 사건의 확률

$$\int_0^{\infty} I_{[\theta < 5]}(\theta) p(\theta) d\theta = \int_0^5 1 \cdot p(\theta) d\theta + \int_5^{\infty} 0 \cdot p(\theta) d\theta = P(\theta < 5).$$

평균 구하기 :  $E(I_{[\theta < 5]}\theta)$

$\theta \sim \text{Gamma}(a, b)$

$$\theta_i^* \quad i = 1, 2, \dots, m \longrightarrow \frac{1}{m} \sum_{i=1}^m I_{\theta^* < 5}(\theta_i^*)$$

# 몬테카를로 추정을 통해 다양한 integrals 계산 가능

예) 백분위수 구하기

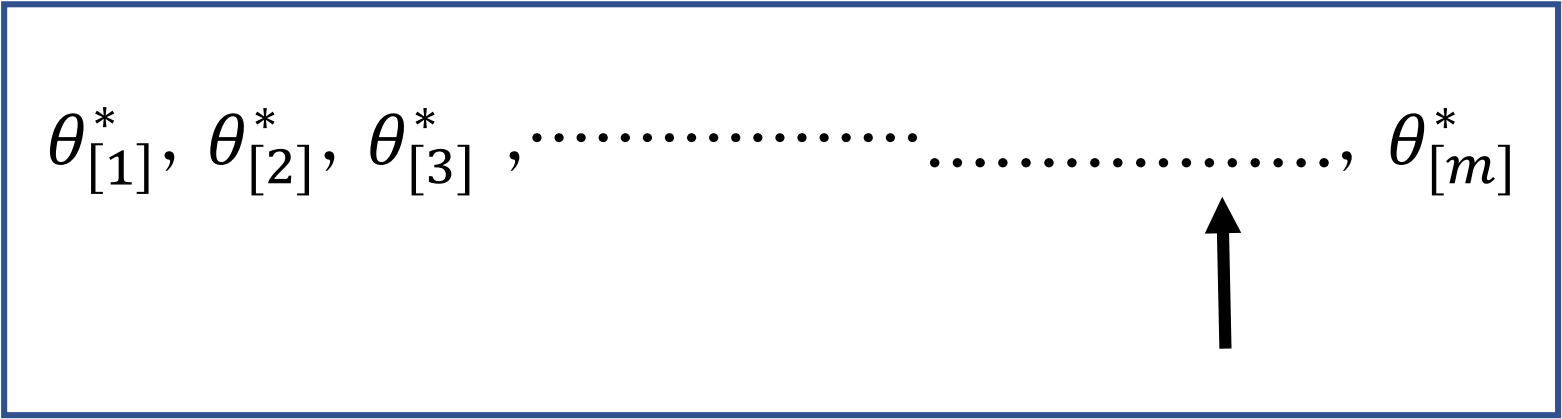
$$P(\theta < z) = 0.9$$

z 찾고 싶다!

$\theta \sim \text{Gamma}(a, b)$

$\theta_i^* \quad i = 1, 2, \dots, m$

$\theta_{[1]}^*, \theta_{[2]}^*, \theta_{[3]}^*, \dots, \dots, \dots, \theta_{[m]}^*$



## Monte Carlo error(=Monte Carlo standard deviation)

Monte Carlo 방법을 이용해서 구한 approximation이 실제 값과 얼마나 차이가 있나

예)  $E(\theta)$ 를 알고 싶을 때  $\leq$  표본 평균으로 추정할 수 있다

$$\overline{\theta^*} \sim N(E(\theta), \frac{Var(\theta)}{m}) \quad \text{by CLT}$$

Monte Carlo standard deviation(se):  $\frac{sd(\theta^*)}{\sqrt{m}}$

만약  $m$ 이 크다면, 실제 값이  
추정치  $\pm 2 \cdot se$  안에 있다고 생각 가능

# Marginalization

$$\{(y_1^*, \phi_1^*), \dots, (y_m^*, \phi_m^*)\}$$


몬테카를로 추정의 장점:

결합된 데이터가 생성되어 있다면 marginalization 쉽게 할 수 있다

=> phi 버리고 y만 marginal dist'n의 sample로 보기

$$p(y) = \int_0^1 p(y, \phi) d\phi$$

Integral로 계산하는 것은 힘들.





# Markov Chain



마르코프 성질: 각 상태는 이전의 상태에 영향을 받는다.  
각 상태는 바로 이전의 상태에만 영향을 받는다.(1차 마르코프 체인)

0차 마르코프 체인

1차 마르코프 체인


2차 마르코프 체인



0차 마코프 체인



1차 마코프 체인



2차 마코프 체인

## Markov Chain

Markov assumption:  $X_{t+1}$  에서의 확률분포는  $X_t$  에 의해서만 결정되어야 한다.

$$p(X_{t+1} | X_t, X_{t-1}, \dots, X_2, X_1) = p(X_{t+1} | X_t) \quad \text{for all } t=2, \dots, n$$

$$p(X_1, X_2, \dots, X_n) = p(X_1) \cdot p(X_2 | X_1) \cdot p(X_3 | X_2, X_1) \cdot \dots \cdot p(X_n | X_{n-1}, X_{n-2}, \dots, X_2, X_1)$$



$$p(X_1, X_2, \dots, X_n) = p(X_1) \cdot p(X_2 | X_1) \cdot p(X_3 | X_2) \cdot p(X_4 | X_3) \cdot \dots \cdot p(X_n | X_{n-1})$$

가정 하나 더) 전이 확률은 시간에 따라 바뀌지 않는다.

## Markov Chain 예시

### Discrete Markov chain 예시

초기 숫자 정한 후(1, 2, 3, 4, 5만 가능) 동전 던져서 앞면 나오면 이전 숫자 +1, 뒷면 나오면 이전 숫자 -1로 만드는 시행을  $n$ 번 반복

상태: 가능한 숫자 1, 2, 3, 4, 5

### Continuous Markov chain 예시

Random walk:  $X_t = 0$  ,  $p(X_{t+1}|X_t=x_t)=N(x_t,1)$

즉 다음 상태의 확률 분포가 평균이 현재 상태, 분산이 1인 정규분포 따른다.

## Transition matrix

각각의 상태에 따른 확률: 전이 확률

전이 확률로 만든 행렬: 전이 행렬

상태에서 상태로 변하는 것을 행렬의 행, 열 성분을 통해 표현함.

예) discrete Markov chain 예시 이어서

전이 확률: 25개 존재 가능

$p(X_{t+1}=5|X_t=4)$

$$Q = \begin{pmatrix} 0 & .5 & 0 & 0 & .5 \\ .5 & 0 & .5 & 0 & 0 \\ 0 & .5 & 0 & .5 & 0 \\ 0 & 0 & .5 & 0 & .5 \\ .5 & 0 & 0 & .5 & 0 \end{pmatrix}$$

## Transition matrix

각각의 상태에 따른 확률: 전이 확률  
 전이 확률로 만든 행렬: 전이 행렬  
 상태에서 상태로 변하는 것을 행렬의 행, 열 성분으로 표현함.

$$Q = \begin{pmatrix} 0 & .5 & 0 & 0 & .5 \\ .5 & 0 & .5 & 0 & 0 \\ 0 & .5 & 0 & .5 & 0 \\ 0 & 0 & .5 & 0 & .5 \\ .5 & 0 & 0 & .5 & 0 \end{pmatrix}$$

예) discrete Markov chain 예시 이어서

Chain에서 여러 step 이후의 확률 구하고 싶을 때 전이 행렬 유용  
 $P(X_{t+2}=3|X_t=1)$

$$Q^2 :$$

	[,1]	[,2]	[,3]	[,4]	[,5]
[1,]	0.50	0.00	0.25	0.25	0.00
[2,]	0.00	0.50	0.00	0.25	0.25
[3,]	0.25	0.00	0.50	0.00	0.25
[4,]	0.25	0.25	0.00	0.50	0.00
[5,]	0.00	0.25	0.25	0.00	0.50

## Stationary distribution

Stationary: 움직이지 않는, 정지한

평형 상태에 도달한 state의 확률분포

먼 미래에는 현재 상태의 중요도가 떨어짐.

초기값에 연연하지 않음.

모든 Markov chain에 존재하는 것은 아님. 수렴하는 조건이 있음.

```
c(0.2, 0.2, 0.2, 0.2, 0.2) %*% Q
```

```
##      [,1] [,2] [,3] [,4] [,5]  
## [1,] 0.2 0.2 0.2 0.2 0.2
```

Simulating long Markov chain

```
table(x) / n
```

```
## x
##   1   2   3   4   5
## 0.1996 0.2020 0.1980 0.1994 0.2010
```

$\approx$

Stationary distribution

```
c(0.2, 0.2, 0.2, 0.2, 0.2) %*% Q
```

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,]  0.2  0.2  0.2  0.2  0.2
```



THANK YOU :)



# Marginalization

Hierarchical model에서도 Monte Carlo sample을 얻을 수 있다

예)) Likelihood:  $y|\phi \sim \text{iid Bin}(10, \phi)$   
Prior:  $\phi \sim \text{Beta}(2, 2)$

Joint distribution:  
 $p(y, \phi) = p(y|\phi)p(\phi)$

$\theta_i^*$  from  $\text{beta}(2, 2)$   $\longrightarrow$   $y_i^*$  from  $\text{Bin}(10, \theta_i^*)$   $\Rightarrow \{(y_1^*, \phi_1^*), \dots, (y_m^*, \phi_m^*)\}$

m번 반복